

# Introducción

El presente documento detalla todos los procesos realizados durante la primera experiencia de aprendizaje “Técnicas de Manipulación de Datos”, aplicados en un primer entregable para un proyecto realista con datos, desde el análisis inicial hasta la preparación para modelado.

Este informe está seccionado en los siguientes apartados:

- Presentación del caso a desarrollar y la estructura del proyecto.
- Preparación del entorno de trabajo (Conda).
- Análisis exploratorio de datos (EDA) inicial.
- Transformación y limpieza de datos.
- Reportes estadísticos y visualizaciones.
- Resultados, conclusiones y recomendaciones.

## Caso a desarrollar

El caso a desarrollar encuentra su origen en el dataset [Student Depression Dataset](#), publicado en Kaggle por el usuario Shodolamu Opeyemi en 2025.

Este dataset consiste en un único archivo CSV (archivo separado por comas), compuesto de un total de 18 columnas de datos y 27901 registros (filas), con los cuales se busca determinar una tasa de depresión en estudiantes de diferentes ciudades en el mundo.

El detalle de cada una de las columnas del dataset es desplegado a continuación:


- **ID:** Identificador único para cada estudiante.
- **Age:** Edad del estudiante.
- **Gender:** Género del estudiante (ej: Masculino, Femenino).
- **City:** Ciudad donde reside el estudiante.
- **CGPA:** Promedio de notas a lo largo de toda su carrera.
- **Sleep Duration:** Duración promedio de las horas de sueño.
- **Profession:** Profesión del estudiante (si aplica).
- **Work Pressure:** Presión que sufre desde su trabajo (si aplica) (medido de 1 a 5).
- **Academic Pressure:** Presión que sufre en el ámbito académico (medido de 1 a 5).
- **Study Satisfaction:** Índice de satisfacción respecto de sus estudios (medido de 1 a 5).
- **Job Satisfaction:** Índice de satisfacción respecto de su trabajo (si aplica) (medido de 1 a 5).
- **Dietary Habits:** Indicador de hábitos alimenticios (ej: saludable, no saludable).
- **Degree:** Grado académico del estudiante.
- **Have you ever had suicidal thoughts?:** ¿El estudiante ha tenido pensamientos suicidas? (sí / no)
- **Work / Study hours:** Horas promedio de trabajo o estudio diarios.
- **Financial Stress:** Índice de estrés financiero (medido de 1 a 5).
- **Family history of mental illness:** ¿La familia del estudiante posee historial de enfermedades mentales? (sí / no).
- **Depression:** Variable target que, en base a todas las columnas anteriores, determina entonces si el estudiante posee o no posee depresión (sí / no).

Escogimos este caso para desarrollar dado que la salud mental es uno de los temas más importantes dentro de los últimos tiempos, especialmente en estudiantes universitarios.

Un estudio interno de la Universidad de Chile (2023) identificó que la prevalencia de trastornos de salud mental en estudiantes de primer año podría llegar hasta el 50%, tanto en síntomas ansiosos como depresivos. Por lo que, aunque este dataset recolecte datos desde diferentes partes del mundo, nos habla de una realidad de la cual nuestro país no se encuentra al margen.

## Estructura de Proyecto

Para organizar este proyecto de forma exitosa, se ha propuesto la siguiente estructura de carpetas:



- ✓ En data/, se almacenarán los datos antes y después de procesar.
- ✓ En notebooks/, se guardarán los archivos .ipynb para EDA y visualización.
- ✓ En src/, se tendrán las funciones auxiliares para visualizar y limpiar datos.
- ✓ En outputs/, se guardarán gráficos y reportes de utilidad.
- ✓ En docs/, se tendrá la documentación del proyecto.

## Ciclo de vida del proyecto

El proyecto se divide en 4 fases:

- **Fase 1 – Setup:** Creación del entorno virtual y repositorio en Git, carga de datos y verificación inicial (contar filas, identificar tipos de datos y demás).
- **Fase 2 – EDA y Limpieza Profunda:** Identificar outliers o datos nulos, aplicar transformaciones y justificar cada decisión.
- **Fase 3 – Ingeniería de Features:** Asegurar que el dataset final tiene la forma y calidad esperada antes de pasar a "producción".
- **Fase 4 – Obtención de resultados:** Analizar los datos limpios para extraer conclusiones, reportes y gráficos de utilidad. Documentar conclusiones rescatadas.

## Alcance de la experiencia

Con lo anteriormente señalado, los alcances del proyecto durante esta primera fase serán preparar los datos, mediante justificación estadística, para en un futuro aplicarlos en un proceso de aprendizaje automático. A su vez, demostrar el uso correcto de herramientas de python avanzadas como las librerías Scikit-Learn, Numpy, Pandas y Matplotlib.