




2026

SCY1101-800D

Programación Para la Ciencia de Datos

Proyecto “Student Depression”

Experiencia de Aprendizaje 1

Técnicas de Manipulación de Datos

Abel Aravena – Benjamín Aravena – Gabriel Castillo

Contenido

Introducción	2
Caso a desarrollar	3
Estructura de Proyecto	4
Ciclo de vida del proyecto.....	4
Alcance de la experiencia	4
Fase 1: Setup	5
Fase 2: EDA y Limpieza	6
Fase 3: Transformación avanzada	7
Fase 4: Análisis de datos, reportes y gráficos	8
Conclusiones	10

Introducción

El presente documento detalla todos los procesos realizados durante la primera experiencia de aprendizaje “Técnicas de Manipulación de Datos”, aplicados en un primer entregable para un proyecto realista con datos, desde el análisis inicial hasta la preparación para modelado.

Este informe está seccionado en los siguientes apartados:

- Presentación del caso a desarrollar y la estructura del proyecto.
- Preparación del entorno de trabajo (Conda).
- Análisis exploratorio de datos (EDA) y limpieza de datos.
- Codificación de datos para un entorno de ML.
- Análisis de datos: reportes estadísticos y visualizaciones.
- Conclusiones y referencias.

Caso a desarrollar

El caso a desarrollar encuentra su origen en el dataset [Student Depression Dataset](#), publicado en Kaggle por el usuario Shodolamu Opeyemi en 2025.

Este dataset consiste en un único archivo CSV (archivo separado por comas), compuesto de un total de 18 columnas de datos y 27901 registros (filas), con los cuales se busca determinar una tasa de depresión en estudiantes de diferentes ciudades en el mundo.

El detalle de cada una de las columnas del dataset es desplegado a continuación:


- **ID:** Identificador único para cada estudiante.
- **Age:** Edad del estudiante.
- **Gender:** Género del estudiante (ej: Masculino, Femenino).
- **City:** Ciudad donde reside el estudiante.
- **CGPA:** Promedio de notas a lo largo de toda su carrera.
- **Sleep Duration:** Duración promedio de las horas de sueño.
- **Profession:** Profesión del estudiante (si aplica).
- **Work Pressure:** Presión que sufre desde su trabajo (si aplica) (medido de 1 a 5).
- **Academic Pressure:** Presión que sufre en el ámbito académico (medido de 1 a 5).
- **Study Satisfaction:** Índice de satisfacción respecto de sus estudios (medido de 1 a 5).
- **Job Satisfaction:** Índice de satisfacción respecto de su trabajo (si aplica) (medido de 1 a 5).
- **Dietary Habits:** Indicador de hábitos alimenticios (ej: saludable, no saludable).
- **Degree:** Grado académico del estudiante.
- **Have you ever had suicidal thoughts?:** ¿El estudiante ha tenido pensamientos suicidas? (sí / no)
- **Work / Study hours:** Horas promedio de trabajo o estudio diarios.
- **Financial Stress:** Índice de estrés financiero (medido de 1 a 5).
- **Family history of mental illness:** ¿La familia del estudiante posee historial de enfermedades mentales? (sí / no).
- **Depression:** Variable target que, en base a todas las columnas anteriores, determina entonces si el estudiante posee o no posee depresión (sí / no).

Escogimos este caso para desarrollar dado que la salud mental es uno de los temas más importantes dentro de los últimos tiempos, especialmente en estudiantes universitarios.

Un estudio interno de la Universidad de Chile (2023) identificó que la prevalencia de trastornos de salud mental en estudiantes de primer año podría llegar hasta el 50%, tanto en síntomas ansiosos como depresivos. Por lo que, aunque este dataset recolecte datos desde otra parte del mundo, nos habla de una realidad de la cual nuestro país no se encuentra al margen.

Estructura de Proyecto

Para organizar este proyecto de forma exitosa, se ha propuesto la siguiente estructura de carpetas:



- ✓ En data/, se almacenarán los datos antes y después de procesar.
- ✓ En notebooks/, se guardarán los archivos .ipynb para EDA y visualización.
- ✓ En src/, se tendrán las funciones auxiliares para visualizar y limpiar datos.
- ✓ En outputs/, se guardarán gráficos y reportes de utilidad.
- ✓ En docs/, se tendrá la documentación del proyecto.

Ciclo de vida del proyecto

El proyecto se divide en 4 fases:

- **Fase 1 – Setup:** Creación del entorno virtual y repositorio en Git, carga de datos y verificación inicial (contar filas, identificar tipos de datos y demás).
- **Fase 2 – EDA y Limpieza Profunda:** Identificar outliers o datos nulos, aplicar transformaciones y justificar cada decisión.
- **Fase 3 – Ingeniería de Features:** Asegurar que el dataset final tiene la forma y calidad esperada antes de pasar a "producción".
- **Fase 4 – Obtención de resultados:** Analizar los datos limpios para extraer conclusiones, reportes y gráficos de utilidad. Documentar conclusiones rescatadas.

Alcance de la experiencia

Con lo anteriormente señalado, los alcances del proyecto durante esta primera fase serán preparar los datos, mediante justificación estadística, para en un futuro aplicarlos en un proceso de aprendizaje automático. A su vez, demostrar el uso correcto de herramientas de python avanzadas como las librerías Scikit-Learn, Numpy, Pandas y Matplotlib.

Fase 1: Setup

El proyecto se inició con la creación de un entorno virtual utilizando **Conda**, asegurando la reproducibilidad mediante un archivo `environment.yml`.

Se estableció un repositorio en **GitHub** con una estructura de ramas (Git Flow) para el trabajo colaborativo y el control de versiones eficiente.

Commits on Apr 6, 2026	
Merge pull request #2 from 0Trickster/feature/analisis-benja 	 1e41ff1  <>
 ipynbenja authored 11 minutes ago	
Phase 3 errors fixed (Retain Depression column as target variable for ML), Phase 4 documentation finished.	1024886  <>
 ipynbenja committed 15 minutes ago	
Commits on Apr 5, 2026	
README corrigendum	7c8e176  <>
 Geboc2006 committed 2 hours ago	
Updated the README and code documentation. Additionally, the cache in the .pyc folder was cleared.	67256d0  <>
 Geboc2006 committed 2 hours ago	
Phase 3: CSV encoding	1765a53  <>
 0Trickster committed 8 hours ago	
Merge pull request #1 from 0Trickster/feature/analisis-benja 	 3719045  <>
 0Trickster authored 11 hours ago	

Se importó el *Student Depression Dataset* original, el cual consta de **27,901 registros** y **18 columnas**. La auditoría inicial mediante las librerías Pandas y Numpy reveló una mezcla de variables numéricas (como Age y CGPA) y categóricas (como City, Gender y Degree). Se verificó la integridad de los tipos de datos, asegurando que las variables cuantitativas fueran reconocidas correctamente para cálculos estadísticos posteriores

La fase de Setup, además, validó la funcionalidad de la modularidad mediante el uso de la función auxiliar `cargar_csv()` desde `src/carga.py`.

Fase 2: EDA y Limpieza

(Para efectos de mejor lectura, se optó por subdividir esta fase en las fases 2A y 2B dentro de los notebooks).

Durante el análisis exploratorio, se identificaron tres puntos clave que determinaron la estrategia de las fases siguientes:

- **Redundancia:** Se observó que 27,870 registros en la columna `Profession` pertenecían a la categoría "Student", lo que representa el **99.8% de la muestra**. Dada esta falta de variabilidad, se determinó que la columna no aportaría información relevante para un modelo predictivo y se marcó para su eliminación.
- **Valores en 0:** Las columnas `Job Satisfaction` y `Work Pressure` presentaban una asimetría demasiado anormal. Tras revisarlas por separado, resultaron ser columnas llenas de principalmente valores en 0 (cuando la escala era de 1 a 5). Dado lo anterior, se consideraron irrelevantes y fueron eliminadas.
- **Ruido en variables categóricas:** Las columnas `City` y `Degree` presentaban una dispersión excesiva de categorías, incluyendo valores con frecuencias menores a 5. Se propuso una estrategia de "Agrupación de Minorías" para evitar el sobreajuste en la fase de modelado.
- **Inconsistencias en Sleep Duration y Dietary Habits:** Se detectaron valores etiquetados como "Others" en contextos donde las opciones predefinidas ya eran exhaustivas. Estos registros se trataron como datos ruidosos/vacíos, sugiriendo su remoción en la fase de limpieza para mantener la calidad de la información.
- **Valores nulos:** Detectados únicamente en la columna `Financial Stress`.

Tras el diagnóstico de la Fase 2A, se procedió a resolver ausencia de datos:

- Para la variable `Financial Stress`, se utilizó la **mediana** como medida de tendencia central. Esta decisión se fundamentó en que la media podría arrojar valores decimales en una columna que solo almacena enteros.
- Se analizaron las columnas `Age` y `CGPA`, filtrando aquellos registros que se encontraban fuera del rango de confianza estadística (método 3 sigma).
- En las variables `Sleep Duration` y `Dietary Habits`, se eliminaron los registros marcados como "Others". Dado que estas categorías ya eran exhaustivas, estos valores se consideraron ruido que no aportaba información interpretable para el análisis de salud mental.
- Se ejecutó el descarte definitivo de las columnas `Profession`, `Job Satisfaction` y `Work Pressure`, dada su nula variabilidad.

Tras limpiar, aplicando todos los filtros y transformaciones, se logró conservar el **99.7% de la información original**, eliminando únicamente el 0.3% de los datos (84 filas).

Fase 3: Transformación avanzada

Para garantizar un procesamiento consistente, se construyó un pipeline utilizando Scikit-Learn. Esta estructura permite aplicar diferentes tratamientos según la naturaleza de la variable en un solo flujo de ejecución:

- **Codificación Categórica Nominal (OneHotEncoder):** Se aplicó a Gender, Sleep Duration, Dietary Habits y Degree. Se utilizó el parámetro `drop='first'` para evitar la multicolinealidad, reduciendo la redundancia matemática en la matriz resultante.
- **Codificación Binaria (OrdinalEncoder):** Las variables “Have you ever had suicidal thoughts ?” y “Family history of mental illness” fueron transformadas mediante un codificador ordinal, permitiendo que el modelo interprete las respuestas yes/no de forma binaria (0 y 1).
- **Normalización Numérica (StandardScaler):** Variables como Age, Academic Pressure, CGPA, Study Satisfaction, Work/Study Hours y Financial Stress fueron estandarizadas. Este paso es crítico, ya que lleva todas las escalas a una media 0 y desviación estándar 1, evitando que variables con números grandes (como la edad) dominen sobre variables de rango pequeño (como el CGPA).
- Se implementó una configuración de `remainder='passthrough'` en el transformador de columnas. Esto permitió mantener la variable **Depression** dentro del flujo de datos sin someterla a transformaciones innecesarias, asegurando que el dataset final conserve su variable “target” para la etapa de entrenamiento del modelo.

```
pipeline = ColumnTransformer(  
    transformers=[  
        ('cat', OneHotEncoder(handle_unknown='ignore', drop='first', sparse_output=False),  
         ['Gender', 'Sleep Duration', 'Dietary Habits', 'Degree']),  
        ('bin', OrdinalEncoder(),  
         ['Have you ever had suicidal thoughts ?', 'Family History of Mental Illness']),  
        ('num', StandardScaler(),  
         ['Age', 'Academic Pressure', 'CGPA', 'Study Satisfaction', 'Work/Study Hours',  
          'Financial Stress']),  
    ],  
    remainder='passthrough'
```


El proceso de ingeniería resultó en una expansión controlada de la dimensionalidad:

- **Dimensionalidad Final:** El dataset pasó de tener 11 variables de entrada a **25 columnas técnicas** (tras la expansión del One-Hot Encoding).
- **Consistencia de Datos:** Se mantuvo el total de **27,817 registros** limpios.

Fase 4: Análisis de datos, reportes y gráficos

En la fase de análisis, se realizaron diferentes hallazgos de interés. A continuación se resumen los más relevantes:


Distribución etaria de estudiantes con depresión




Se realizó una segmentación por rangos de edad para identificar los grupos más vulnerables.

Mediante un gráfico de torta, se determinó que la prevalencia de la depresión es significativamente mayor en los estudiantes de menor edad (segmento de "Class 12" y primeros años de carrera). Esta observación sugiere que la transición a la educación superior y la carga académica inicial son factores críticos de estrés.

Se construyó una matriz de correlación de Pearson para cuantificar la fuerza de asociación entre las variables. Para ello, se mapearon variables categóricas clave (como el género) a valores numéricos. Al visualizar esto como un mapa de calor, los hallazgos principales fueron:



- **Relación Crítica:** Se confirmó una correlación positiva fuerte de **0.55** entre la Depresión y los Pensamientos Suicidas, validando la gravedad del problema analizado.
- **Presión Académica:** Esta variable externa resultó ser el predictor más influyente (**0.48**), superando a factores como el estrés financiero u horas de estudio.



Otro de los descubrimientos más reveladores del análisis fue la **correlación prácticamente nula (-0.02)** entre el promedio de notas (CGPA) y la depresión.

Esto indica que el éxito académico y el bienestar emocional son variables independientes. Un estudiante con excelentes calificaciones tiene el mismo riesgo de sufrir depresión que uno con bajo rendimiento. Este hallazgo es fundamental para desmitificar que el buen promedio es un indicador de salud mental.

En cuanto al sueño, un reporte generado destacó el cómo aquellas personas que dormían menos de 5 horas diarias presentaban una mayor probabilidad de ser diagnosticadas con depresión.

	Duración del sueño	NO Tiene depresión	Tiene Depresión
0	5-6 hours	43.12	56.88
1	7-8 hours	40.45	59.55
2	Less than 5 hours	35.46	64.54
3	More than 8 hours	49.06	50.94

Conclusiones

La Experiencia 1 cumplió con el objetivo de transformar un conjunto de datos crudos en un activo de información estructurado. Las 4 fases realizadas, desde el setup hasta el análisis, demostraron que un flujo de trabajo basado en pipelines permite una manipulación de datos auditable, escalable y profesional.

- El pipeline de datos es robusto y escalable para nuevos registros.
- Para la Experiencia 2, se recomienda probar modelos de ensamble (como Random Forest) dado que hay muchas variables categóricas codificadas que podrían tener interacciones no lineales.

Desde una perspectiva al análisis y al tema que nos convocó para este proyecto, podemos concluir que **las instituciones académicas deben implementar sistemas de alerta temprana basados en la percepción de presión del estudiante, más que en el monitoreo del promedio de calificaciones, para prevenir cuadros depresivos de manera efectiva.**

Referencias

Universidad de Chile. (2023, marzo 23). *Hasta 50% de las y los universitarios manifestarían síntomas de ansiedad y depresión*. <https://uchile.cl/noticias/203446/hasta-50-de-universitarios-tendrian-sintomas-de-ansiedad-y-depresion>

Shodolamu, Opeyemi (2025). *Student depression dataset*. Kaggle. <https://www.kaggle.com/datasets/hopesb/student-depression-dataset/data>